Финансовый университет при Правительстве Российской Федерации
Департамент анализа данных и машинного обучения

Лабораторная работа 2
Мультимодальные модели для адаптации визуального домена

По теме ВКР «Сравнительный анализ методов выравнивания распределений для адаптации домена в задачах компьютерного зрения»

Выполнила: А. Д. Якумова

2026

Аннотация

Проверено, помогают ли текстовые описания и числовые характеристики изображения перенести распознавание объектов из фотографий товаров Product на рисунки Clipart. Изображение и текст кодировались предобученной SigLIP 2; 19 числовых характеристик измерялись непосредственно на исходном изображении. Сравнены восемь схем объединения признаков, MMD и CORAL, одномодальные контроли и zero-shot распознавание. На Clipart лучшим ориентиром оказалось прямое zero-shot применение SigLIP 2: Macro-F1 0,879 против 0,634 у выбранной по Product схемы объединения. Для Office-Home добавление зависимых от изображения текста и чисел не улучшило перенос. На дополнительном наборе Digits обнаружен эффект выравнивания, но его нельзя приписать объединению без сравнения с визуальной моделью с тем же выравниванием.

1 Постановка и связь с темой ВКР

Адаптация домена изучает ситуацию, когда обучающие и рабочие изображения имеют разные распределения. Здесь метки объектов доступны для фотографий Product, а целевые рисунки Clipart при настройке выравнивания считаются неразмеченными. MMD сближает распределения признаков через расстояние между средними в ядровом пространстве; CORAL сближает ковариационные матрицы. Оба метода не требуют истинных меток Clipart. Основная метрика — Macro-F1, то есть среднее F1 по всем 65 классам с одинаковым весом каждого класса.

SigLIP 2 — предобученный кодировщик изображения и текста с общей семантической областью признаков. Это мультимодальная модель, но не генеративная LLM: в данном опыте она не пишет ответ, а возвращает числовые векторы и сходство изображения с текстовым названием класса. Текстовый вход для схем объединения — первые шесть автоматических меток Apple Vision для того же изображения, без обращения к истинному классу. Числовой вход — статистики того же изображения. Поэтому работа исследует полезность трёх представлений одного объекта, а не независимых сенсоров.

2 Обзор исследований и исследовательский вопрос

Обзор охватывает 15 первичных работ. Office-Home задаёт визуальные домены; DAN и Deep CORAL — базовые способы выравнивания; CLIP, SigLIP 2 и DPA показывают, как семантика текста может участвовать в распознавании и адаптации. Работы по тексту, таблицам, временным рядам и финансам нужны для сопоставления с полным заданием лабораторной. Они не служат доказательством, что Office-Home содержит временной ряд. Полная матрица с кодированием, схемой объединения, данными, метриками, доступностью кода и ограничениями сохранена в literature/matrix.csv.

Таблица 1 — Сопоставление 15 работ по способу объединения и применимости

№	Работа	Выравнивание или объединение	Задача и данные	Код
01	Venkateswara H. [и др.] (2017)	domain alignment in feature space	Office-Home object recognition	ссылка в матрице
02	Long M. [и др.] (2015)	multi-kernel MMD loss	unsupervised visual domain adaptation	ссылка в матрице
03	Sun B., Saenko K. (2016)	covariance matching loss	unsupervised visual domain adaptation	ссылка в матрице
04	Ganin Y. [и др.] (2016)	gradient reversal / domain discriminator	source-target transfer	не проверен
05	Long M. [и др.] (2018)	conditional adversarial alignment	visual UDA including Office-Home	ссылка в матрице
06	Radford A. [и др.] (2021)	contrastive common space	zero-shot image classification	ссылка в матрице
07	Li J. [и др.] (2023)	Q-Former bridge	vision-language understanding and generation	ссылка в матрице
08	Liu H. [и др.] (2023)	projection into language context	image instruction following	ссылка в матрице
09	Ali E., Silva S., Khan M. H. (2025)	prototype alignment and pseudo-label fusion	unsupervised VLM image classification	не проверен
10	Tsai Y.-H. [и др.] (2019)	directional cross-modal attention	multimodal sequence classification/regression	ссылка в матрице
11	Jin M. [и др.] (2024)	reprogramming into frozen LLM	time-series forecasting	ссылка в матрице
12	Zhong S. [и др.] (2025)	fusion of VLM embeddings with temporal features	time-series forecasting	ссылка в матрице
13	Yin P. [и др.] (2020)	joint contextual representation	text-table semantic parsing	не проверен
14	Bhatia G. [и др.] (2024)	multimodal financial LLM	financial analysis, nine tasks	ссылка в матрице
15	Tschannen M. [и др.] (2025)	sigmoid contrastive image-text pretraining; similarity at inference	zero-shot classification, retrieval, vision-language transfer	ссылка в матрице

Исследовательский вопрос: сохраняется ли польза MMD/CORAL и добавочных представлений, если исходный визуальный вектор уже получен сильной vision-language моделью? Для ответа нужна проверка не только против слабого визуального классификатора, но и против zero-shot SigLIP 2 и визуальной модели с тем же методом выравнивания.

3 Данные и схема мультимодального объекта

Объект объединяется строго по паре dataset + id. Для Office-Home это JPEG, текст автоматических категорий Apple Vision и 19 числовых величин: средние и стандартные отклонения каналов RGB, насыщенности и яркости, характеристики серого изображения, доли тёмных и светлых пикселей, величина и доля границ, логарифм отношения ширины к высоте. Они рассчитаны один раз на исходном изображении без изменения цвета или яркости. Метка класса хранится отдельно и не поступает на вход кодировщика.

Таблица 2 — Паспорт двух наборов и назначение частей

Набор	Часть	Домен	N	Назначение
Office-Home	source_train	Product	520	обучение головы
Office-Home	validation	Product	130	выбор эпохи и схемы
Office-Home	target_adapt	Clipart	195	безметочное выравнивание
Office-Home	test	Clipart	130	основная оценка
Office-Home	new_slice / external	Art / Real World	130 / 130	другие домены
Digits	source_train / validation	исходный	790 / 198	обучение / выбор
Digits	target_adapt / test	инверсия и окраска	404 / 405	адаптация / оценка

Office-Home содержит 1235 объектов 65 классов; на основном тесте только по два рисунка на класс. Digits содержит 1797 разных рукописных цифр десяти классов: целевой стиль сформирован инверсией, окраской и слабым размытием уже выделенных объектов. Тексты Digits — детерминированное описание геометрии штрихов без названия цифры. Пропусков текста, нечисловых признаков и пересечений групп между частями аудит не обнаружил; точных повторов исходных Digits тоже нет. Результаты аудита и исключений: data/audit.json и data/exclusions.csv.

Office-Home и Digits не содержат наблюдений по календарному времени. Связь по id является объектной синхронизацией; UTC, окно до момента прогноза и отложенный временной период здесь неприменимы. Следовательно, требование задания о настоящем числовом временном ряде и проверке на будущем периоде этим выбором данных не выполнено. Подменять его искусственными стадиями обработки изображения было бы методически неверно.

4 Модель, схемы и протокол

Использован официальный checkpoint google/siglip2-base-patch16-224, ревизия 75de2d55ec2d0b4efc50b3e9ad70dba96a7b2fa2. Замороженные кодировщики дали для каждого объекта 768-мерные векторы изображения и текста. Zero-shot вариант сравнивает вектор изображения с заранее заданными текстами 65 классов Office-Home или десяти цифр и не обучается на целевых рисунках. Три входа классификационной головы — визуальный вектор, текстовый вектор и 19 чисел. У каждой ветви линейное отображение в 128 измерений и ReLU; затем общее отображение и выход по классам.

Таблица 3 — Восемь проверенных схем объединения

Схема	Объединение	Выравнивание
mean	среднее трёх ветвей	нет
mean_mmd	среднее трёх ветвей	MMD
mean_coral	среднее трёх ветвей	CORAL
concat	конкатенация	нет
concat_mmd	конкатенация	MMD
concat_coral	конкатенация	CORAL
gated	обучаемые веса ветвей	нет
gated_coral	обучаемые веса ветвей	CORAL

Контроли: визуальная, текстовая и числовая ветви отдельно; визуальная ветвь с MMD и с CORAL; zero-shot SigLIP 2. Всего обучено 13 × 3 × 2 = 78 голов на трёх фиксированных seed и двух наборах. Оптимизатор AdamW, 30 эпох, batch 64, learning rate 0,001, weight decay 0,0001, вес выравнивания 0,1. Нормировка каждого признака рассчитана только на source_train. В каждой тренировке эпоха выбиралась по Macro-F1 Product validation; схема — по среднему Macro-F1 этой же части между тремя seed. Clipart target_adapt использовался без истинных меток только в функции MMD/CORAL. Тестовые метки не входили в выбор или обучение этой версии кода.

Условие независимого подтверждения ограничено: целевые части Office-Home уже анализировались в прежнем варианте лабораторной. Хотя новый перечень схем и кодировщик закреплены до нынешнего пересчёта, выводы по Clipart, Art и Real World остаются исследовательскими. Статистические интервалы получены стратифицированным по классам bootstrap (2000 повторов); сравнения — парной перестановкой предсказаний (5000 повторов). Множественные сравнения не корректировались.

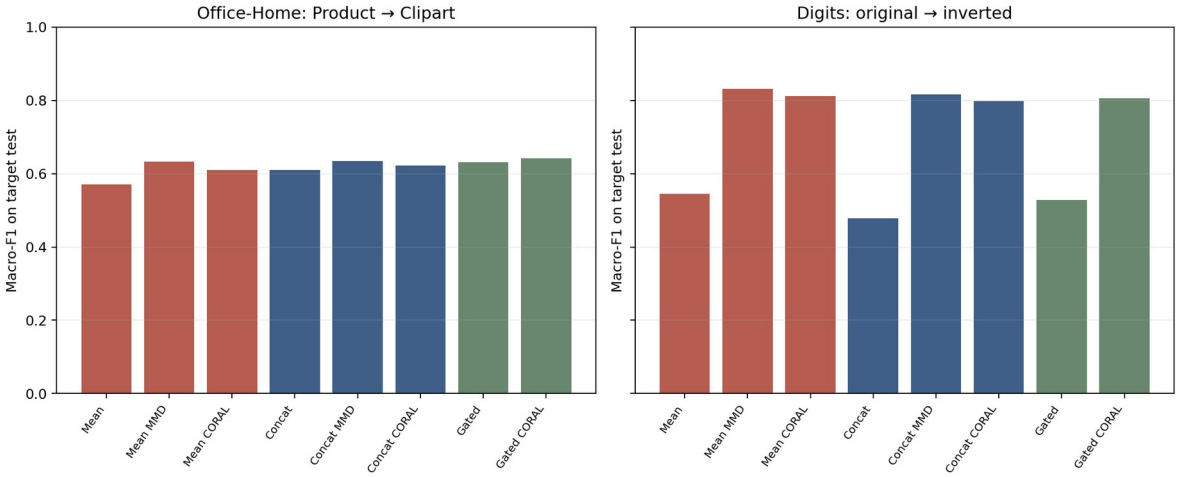
5 Результаты на Office-Home

Таблица 4 — Clipart test, ансамбль трёх seed для обучаемых схем

Схема	Macro-F1	95% ДИ	Accuracy	ECE
visual	0,862	[0,805; 0,897]	0,877	0,354
text	0,248	[0,210; 0,276]	0,300	0,336
numeric	0,026	[0,015; 0,031]	0,023	0,266
visual_mmd	0,845	[0,786; 0,878]	0,862	0,252
visual_coral	0,871	[0,814; 0,905]	0,885	0,357
mean	0,571	[0,497; 0,612]	0,615	0,118
mean_mmd	0,632	[0,550; 0,668]	0,654	0,099
mean_coral	0,610	[0,531; 0,648]	0,638	0,141
concat	0,610	[0,539; 0,652]	0,646	0,108
concat_mmd	0,634	[0,561; 0,674]	0,669	0,098
concat_coral	0,622	[0,554; 0,661]	0,662	0,117
gated	0,632	[0,552; 0,672]	0,662	0,136
gated_coral	0,641	[0,564; 0,682]	0,677	0,138
zero_shot	0,879	[0,825; 0,911]	0,892	0,069

По Product validation выбрана схема concat_mmd. На Clipart она получила Macro-F1 0,634; zero-shot SigLIP 2 — 0,879. Разница -0,245, 95% ДИ [-0,323; -0,187], парный p=0,0004. Положительного эффекта объединения нет. При этом визуальная обученная голова без дополнительных входов дала 0,862, то есть сама сильная визуальная репрезентация уже хорошо переносится.

Рисунок 1 — Macro-F1 восьми схем объединения на двух целевых тестах



6 Контроль выравнивания и второй набор

Таблица 5 — Парные сравнения на целевых тестах

Набор	Сравнение	Разница F1	95% ДИ	p
Office-Home	MMD к визуальной модели	-0,017	[-0,046; 0,008]	0,4415
Office-Home	CORAL к визуальной модели	0,009	[-0,013; 0,033]	0,7429
Office-Home	Слияние при MMD	-0,213	[-0,286; -0,160]	0,0002
Office-Home	Слияние при CORAL	-0,261	[-0,331; -0,213]	0,0002
Office-Home	Zero-shot против visual	0,017	[-0,026; 0,068]	0,6005
Digits	MMD к визуальной модели	0,288	[0,244; 0,336]	0,0002
Digits	CORAL к визуальной модели	0,234	[0,188; 0,284]	0,0002
Digits	Слияние при MMD	0,011	[-0,024; 0,046]	0,5651
Digits	Слияние при CORAL	0,044	[0,008; 0,082]	0,0280
Digits	Zero-shot против visual	-0,107	[-0,158; -0,055]	0,0014

На Digits схема mean_mmd получила Macro-F1 0,832 против 0,533 у обычной визуальной головы: прирост 0,298. Но визуальная голова с тем же MMD уже достигает 0,821; добавление текста и чисел при фиксированном MMD меняет результат только на 0,011, ДИ [-0,024; 0,046]. Следовательно, основной выигрыш на этом искусственном сдвиге связан с выравниванием, а самостоятельный вклад дополнительных входов следует оценивать по этому контрольному сравнению.

Схема, выбранная на Product, дополнительно применена к Art и Real World. Они показывают перенос на другие стили изображения, но не являются более поздними временными периодами. Их показатели и парные интервалы хранятся в results/paired_comparisons.csv; из-за предыдущего просмотра этих частей они рассматриваются как дополнительная диагностика.

7 Вклад входов, пропуски и ошибки

Таблица 6 — Маскирование входа выбранной схемы на целевом тесте

Условие	Office-Home F1	Digits F1
Все входы	0,634	0,832
Без изображения	0,223	0,290
Без текста	0,699	0,731
Без чисел	0,658	0,822
Только изображение	0,775	0,712

Это проверка отсутствующего входа во время применения уже обученной головы: соответствующая ветвь исключается или заполняется нулями. На Office-Home удаление текста повышает Macro-F1 выбранной схемы с 0,634 до 0,699, а чисел — до 0,658; следовательно, эти входы в данной обученной конфигурации мешают. На Digits удаление текста снижает F1 с 0,832 до 0,731, удаление чисел — до 0,822. Маскирование не тождественно отдельному обучению модели без модальности; одномодальные контроли приведены в таблице 4 и сохранены для Digits в results/scheme_intervals.csv.

Таблица 7 — Повторное обучение выбранного семейства без одного входа

Исключённый вход	Office-Home F1	Digits F1
Без изображения	0,303	0,477
Без текста	0,804	0,808
Без чисел	0,637	0,842

При отдельном повторном обучении без текста Office-Home даёт 0,804 вместо 0,634 у полного варианта; без чисел — 0,637. На Digits без чисел получилось 0,842 вместо 0,832. Эти дополнительные абляции назначены после просмотра основных результатов и служат диагностикой, а не независимой проверкой гипотезы.

Выбранная схема ошиблась на 43 из 130 рисунков Clipart и 67 из 405 целевых цифр. На 34 ошибках Clipart zero-shot baseline ответил правильно. Ошибок с уверенностью выше 0,8 соответственно 2 и 20. Для 65 классов два тестовых изображения на класс дают нестабильную по отдельным классам оценку; причинность единичной ошибки без ручной проверки не утверждается.

Таблица 8 — Примеры ошибок объединения при правильном ответе zero-shot

ID	Класс	Ответ схемы	Автоматический текст
4888	Backpack	Bottle	art illustrations tool utensil cookware kettle
3105	Bed	Helmet	art illustrations painting people adult document
5384	Bottle	Soda	drink liquid wine red wine wine bottle drinking glass

8 Качество, ресурсы и решение о применении

Калибровка тоже важна: ECE на Clipart равна 0,069 для zero-shot, 0,354 для визуальной обученной головы и 0,098 для выбранной схемы. ECE зависит от разбиения вероятностей на корзины и при 130 объектах является грубой оценкой. Дополнительно рассчитаны accuracy, MCC, многоклассовая Brier score и NLL; полные значения находятся в results/scheme_intervals.csv.

Извлечение изображений и текстов SigLIP 2 на локальном CPU в пакетах по 16 заняло 68,9 с для 1235 Office-Home объектов и 76,4 с для 1797 Digits. Это включает чтение изображения, вычисление чисел и кодирование уже готового текста, но не первоначальное получение меток Apple Vision. Файл весов SigLIP 2 занимает около 1,5 ГБ; после извлечения в проекте остаются компактные векторы и обучаемые головы. Время собственно голов измерено отдельно в results/metrics.csv. Денежных расходов внешнего API в этом запуске не было.

Для основной задачи Product → Clipart практический выбор — прямое zero-shot использование SigLIP 2, а не выбранная трёхвходовая схема. Для задачи сравнения методов выравнивания при фиксированном backbone следует отдельно сопоставлять visual, visual+MMD и visual+CORAL; их разницы малы относительно уже высокого качества признаков. На Digits выравнивание существенно, но это искусственный сдвиг и другая задача, поэтому его результат нельзя переносить на Office-Home.

9 Ограничения и воспроизводимость

Главные ограничения: небольшая и ранее просмотренная целевая часть Office-Home; два объекта на класс; множественные исследовательские сравнения; неизвестное пересечение данных предобучения SigLIP 2 с изображениями Office-Home; системно управляемая версия Apple Vision; текст и числовые признаки, зависящие от того же изображения; искусственный сдвиг Digits. Отсутствие настоящих временных рядов не позволяет заявить выполнение части задания о временной синхронизации и проверке на будущем периоде. Для такого вывода нужен иной набор с независимым текстовым и последовательным числовым потоком.

Воспроизведение обеспечивают зафиксированная ревизия SigLIP 2, requirements.txt, configs/protocol.json, исходные коды извлечения, обучения и анализа, data/schema.json, аудит, исключения, истории 78 основных и 18 абляционных обучений, сохранённые головы и вероятности предсказаний. Метки целевого домена не используются в обучении и выборе, что проверяется по коду. Числа демонстрационного финансового примера задания в результаты не переносились.

Список литературы

1. Venkateswara H. [и др.]. Deep Hashing Network for Unsupervised Domain Adaptation // CVPR. — 2017. — URL: https://openaccess.thecvf.com/content_cvpr_2017/html/Venkateswara_Deep_Hashing_Network_CVPR_2017_paper.html (дата обращения: 22.10.2026). — Текст : электронный.
2. Long M. [и др.]. Learning Transferable Features with Deep Adaptation Networks // ICML. — 2015. — URL: https://proceedings.mlr.press/v37/long15.html (дата обращения: 22.10.2026). — Текст : электронный.
3. Sun B., Saenko K.. Deep CORAL: Correlation Alignment for Deep Domain Adaptation // ECCV workshop / arXiv. — 2016. — URL: https://arxiv.org/abs/1607.01719 (дата обращения: 22.10.2026). — Текст : электронный.
4. Ganin Y. [и др.]. Domain-Adversarial Training of Neural Networks // JMLR. — 2016. — URL: https://jmlr.org/papers/v17/15-239.html (дата обращения: 22.10.2026). — Текст : электронный.
5. Long M. [и др.]. Conditional Adversarial Domain Adaptation // NeurIPS. — 2018. — URL: https://proceedings.neurips.cc/paper_files/paper/2018/hash/ab88b15733f543179858600245108dd8-Abstract.html (дата обращения: 22.10.2026). — Текст : электронный.
6. Radford A. [и др.]. Learning Transferable Visual Models From Natural Language Supervision // ICML. — 2021. — URL: https://proceedings.mlr.press/v139/radford21a.html (дата обращения: 22.10.2026). — Текст : электронный.
7. Li J. [и др.]. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models // ICML. — 2023. — URL: https://proceedings.mlr.press/v202/li23q.html (дата обращения: 22.10.2026). — Текст : электронный.
8. Liu H. [и др.]. Visual Instruction Tuning // NeurIPS. — 2023. — URL: https://proceedings.neurips.cc/paper_files/paper/2023/hash/6dcf277ea32ce3288914faf369fe6de0-Abstract-Conference.html (дата обращения: 22.10.2026). — Текст : электронный.
9. Ali E., Silva S., Khan M. H.. DPA: Dual Prototypes Alignment for Unsupervised Adaptation of Vision-Language Models // WACV, pp. 6083–6093. — 2025. — URL: https://openaccess.thecvf.com/content/WACV2025/html/Ali_DPA_Dual_Prototypes_Alignment_for_Unsupervised_Adaptation_of_Vision-Language_Models_WACV_2025_paper.html (дата обращения: 22.10.2026). — Текст : электронный.
10. Tsai Y.-H. [и др.]. Multimodal Transformer for Unaligned Multimodal Language Sequences // ACL. — 2019. — URL: https://aclanthology.org/P19-1656/ (дата обращения: 22.10.2026). — Текст : электронный.
11. Jin M. [и др.]. Time-LLM: Time Series Forecasting by Reprogramming Large Language Models // ICLR. — 2024. — URL: https://proceedings.iclr.cc/paper_files/paper/2024/hash/680b2a8135b9c71278a09cafb605869e-Abstract-Conference.html (дата обращения: 22.10.2026). — Текст : электронный.
12. Zhong S. [и др.]. Time-VLM: Exploring Multimodal Vision-Language Models for Augmented Time Series Forecasting // ICML. — 2025. — URL: https://proceedings.mlr.press/v267/zhong25a.html (дата обращения: 22.10.2026). — Текст : электронный.

13. Yin P. [и др.]. TaBERT: Pretraining for Joint Understanding of Textual and Tabular Data // ACL. — 2020. — URL: https://aclanthology.org/2020.acl-main.745/ (дата обращения: 22.10.2026). — Текст : электронный.
14. Bhatia G. [и др.]. FinTral: A Family of GPT-4 Level Multimodal Financial Large Language Models // Findings of ACL. — 2024. — URL: https://aclanthology.org/2024.findings-acl.774/ (дата обращения: 22.10.2026). — Текст : электронный.
15. Tschannen M. [и др.]. SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features // arXiv:2502.14786. — 2025. — URL: https://arxiv.org/abs/2502.14786 (дата обращения: 22.10.2026). — Текст : электронный.
Источники данных: Office-Home; scikit-learn Digits (дата обращения: 22.10.2026).

Приложение А Состав числового входа

Каждый показатель вычислен по одному исходному изображению после приведения копии к размеру 128 × 128 пикселей; только отношение сторон берётся из исходных размеров. Значения не являются измерениями во времени.

Таблица А1 — Девятнадцать непосредственных характеристик изображения

Группа	Число	Определение
Средние R, G, B	3	среднее каждого цветового канала
Разброс R, G, B	3	стандартное отклонение каждого канала
Насыщенность и яркость	4	среднее и разброс S и V в HSV
Серый тон	4	среднее, разброс и квантили 10% и 90%
Тёмные и светлые пиксели	2	доли ниже 0,15 и выше 0,85
Границы	2	средний градиент и доля сильных границ
Геометрия	1	логарифм отношения ширины к высоте